

과제 3 보고서: 작은 Iris 분류기에 대한 Marabou 검증

1. Marabou resources 디렉터리 조사

Marabou의 resources 디렉터리는 신경망 검증 예제와 벤치마크를 여러 형식으로 제공한다. nnet 폴더에는 ACAS Xu, CollisionAvoidance, MNIST, TwinStreams처럼 완전연결 ReLU 네트워크가 들어 있고, onnx 폴더에는 작은 완전연결 모델, 합성곱/맥스풀링 예제, MNIST와 CIFAR 계열 모델, 교통표지판 모델, 연산자 테스트 모델이 포함되어 있다. 또한 Keras .h5 MNIST CNN, binary neural network query, property 파일, 실행 스크립트와 Split-and-Conquer 노트북도 제공된다.

property 파일은 입력 변수의 하한/상한과 출력 변수 사이의 선형 부등식을 적는 방식으로 검증 조건을 표현한다. Python API 예제도 같은 구조를 사용해 모델을 읽고, 입력 bound를 설정하고, 출력 제약을 추가한 뒤 SMT solver를 호출한다. 이 조사를 바탕으로 Problem 2에서는 resources에 이미 포함된 ACAS, MNIST, CIFAR, traffic-sign 모델을 피하고 별도의 작은 Iris 모델을 선택했다.

2. 사용한 모델, 데이터셋, 검증 조건

외부 모델로는 Iris 데이터셋의 두 특성, 즉 petal length와 petal width만 사용하는 작은 .nnet 모델을 만들었다. .nnet은 Marabou가 직접 읽을 수 있는 완전연결 ReLU 네트워크 형식이다. 두 입력은 일반적인 Iris feature 범위를 기준으로 $[0, 1]$ 로 정규화했다. 모델 구조는 입력 2개, ReLU hidden unit 3개, Setosa/Versicolor/Virginica에 해당하는 출력 logit 3개이다.

큰 CNN이나 ResNet류 모델은 Marabou에서 시간이 오래 걸릴 수 있으므로, 검증 조건을 직접 이해하고 재현하기 쉬운 작은 완전연결 모델을 사용했다. 기준 입력은 Setosa 샘플 $x = [0.0677966102, 0.0416666667]$ 이며, petal length 1.4 cm와 petal width 0.2 cm에 해당한다. 이 입력에서 모델 logit은 약 $[1.6716, 0.3773, -0.8072]$ 이고 예측 class는 Setosa이다.

검증하고 싶은 성질은 L_∞ 반경 $\epsilon = 0.04$ 안의 모든 입력이 계속 Setosa로 분류되는지이다. Marabou의 선형 출력 제약은 결합 조건으로 넣기 쉽기 때문에, robustness를 두 개의 반례 탐색 query로 나누어 확인했다.

- ϵ box 안에서 Versicolor logit이 Setosa logit 이상이 되는 입력이 존재하는가?
- ϵ box 안에서 Virginica logit이 Setosa logit 이상이 되는 입력이 존재하는가?

각 query는 $y_{\text{setosa}} - y_{\text{rival}} \leq 0$ 을 만족하는 반례가 있는지 묻는다. 두 query가 모두 UNSAT이면 해당 perturbation 영역 안에 예측을 바꾸는 반례가 없으므로 local robustness가 검증된다.

3. 결과 및 해석

test.py를 실행하면 결과가 results/verification_result.json에 저장된다. 기록된 실행에서 $\epsilon = 0.04$ 에 대해 Versicolor 반례 query와 Virginica 반례 query가 모두 UNSAT을 반환했다. 실행 시간은 각각 약 0.0004초와 0.0002초였다. 따라서 선택한 Setosa 입력 주변의 작은 L_∞ perturbation 영역에서는 모델의 Setosa 예측이 유지된다고 해석할 수 있다.

이 결과는 입력이 petal length와 petal width가 모두 작은 Setosa 영역에 있고, 중심점에서 Setosa logit과 다른 class logit 사이의 margin이 충분히 크기 때문에 자연스럽다. 단순히 몇 개의 perturbation 샘플을 테스트한 것이 아니라, 지정한 입력 box 전체에 대해 반례가 없음을 solver가 확인했다는 점이 중요하다.

4. Marabou 사용 경험

Marabou의 장점은 입력 bound와 출력 부등식으로 명확한 검증 문제를 만들면 SAT/UNSAT 형태의 형식적인 답을 준다는 점이다. 반면 모델이 커지거나 ReLU 수가 많아지면 탐색 공간이 급격히 커질 수 있어 확장성은 제한적이다. 또한 여러 class 중 하나라도 target을 이기는지 확인하는 disjunctive robustness 조건은 이번 실험처럼 class별 query로 나누어 작성하는 편이 이해하기 쉬웠다.